

token-burner

一句需求 → 一个可运行的 Web 项目

AI 多智能体项目团队系统 · v2.0 竞赛版 · ARC-Bench 实弹参赛作品

Set your tokens on fire! —— 烧的是 token, 交付的是信任。

一、产品定位：LLM 会写代码，不等于能交付系统

大模型把「写代码」的成本降到了接近零，但**交付一个可运行、可验证的系统**依然无解：生成过程是黑盒、模块集成无人负责、多模型接力的成本随时失控。

token-burner 的答案是把职责一分为二：**「生成」交给多智能体流水线**，**「信任」交给确定性验证层**——七个零 LLM 审计器、两段式验收、模型链全链保护。LLM 负责决策，程序负责校验与边界。

黑盒生成

过程不可审计，质量全凭模型心情

集成无人管

文件单看都对，拼起来 import 断裂、种子丢失

成本失控

无预算闸门，长跑烧穿钱包才发现

二、生产流水线：八段流水，每段有闸门



需求树按 FOLDER/ATOMIC 两级摄取；**分层讨论管线**让讨论阶段只读 26% 体量的 FOLDER 摘要（keep 应用实测 17,125 → 4,495 字符），拆分与开发阶段才消费原子级全文——117~143 需求的大型应用不撞模型推理墙钟。每个模块按依赖拓扑序进入**「写代码 → 写测试 → 接口门禁 → 执行 → 修复/冻结」**五步循环：错误在产生的模块内就地暴露，单模块失败冻结继续，部分交付仍可评测。

三、七类确定性审计器：零 LLM 的质量底盘

每一类都由一次真实运行失败取证驱动，并在真实交付物上回归验证——不是设计出来的，是打出来的。

审计器	职责	实弹取证
schema 审计	DDL vs SQL 列名 diff (INSERT/WHERE/SELECT/表名/限定引用, 5 类检查)	r13/r15 连续命中
包结构审计	import 名 ↔ 实际包名映射 + 空壳包识别	keep3/gen-3
符号级导入审计	from X import sym 静态验证 sym 在 X 内有定义	keep3 auth_bp
机械垫片	命名漂移 → 自动生成 re-export 垫片 (零 LLM 修复)	gen-3 家族终结
子模块自动绑定	from X import X 缺绑定 → 自动补	keep4 seed_data
内存哨兵	应用峰值内存 >512MB 判 FAIL (对齐官方 2GB 环境)	平台 2G 裁决
轨迹取证	失败自动携带应用侧 traceback (file:line) 注入修复指令	r12/r13/r15

四、模型韧性体系：网关退化窗口里也把活干完

全链保护：单模型超时 → 编队内其余模型自动接力 (ModelChainExhausted 专类型，备胎不再裸奔)。

模块级冻结：单模块 LLM 全灭 → 冻结该模块、管线继续其余模块——部分交付 > 归零。

优雅降级：验收失败 → 报告完整保留、干净退出，绝不崩穿平台进程 (官方容器实证)。

配置锚定：config 随提交包锚定 + 官方中转站编制自动补全——备胎链不依赖运行目录。

四层兜底均有专项回归测试；generation-2/4 两次失败 → 四件套修复提交，回归 1225 → 1231 passed。

五、视觉通道与成本治理

视觉转写通道：需求树内嵌参考截图自动经视觉模型转写为结构化中文描述注入需求文本。 平台容器注入 VISUAL_MODEL=gpt-5.5 + VISUAL_BASE_URL (generation-4 容器日志取证) ， 官方视觉通道优先、中转站 kimi/minimax 兜底；带描述缓存与幻觉防线（无效图绝不上发）。 官方 keep 应用 22 张截图实测全识别。

成本治理：六层护栏（预算总闸 → 讨论轮数 → 循环检测 → 修复上限 → spec 收敛 → 输出截断）， 全程 token 审计落盘 logs/cost_report.json。单模块失败冻结继续、超支干净中止 + 现场落盘 + 断点续跑（resume 实战验证）。

¥15-30

Train Ticket 单任务实测成本
(750k~1.2M token)

2,000,000

单任务预算总闸（超支干净中止
可续跑）

1231

自动化回归测试全绿（全 stub
无需密钥）

6 次

官方容器实弹运行

六、实弹战绩（全部可复核）

战场	修复前	修复后	说明
SWE-bench Lite	resolved 1/50 (2%) , 2.96M tokens	同域新样本 3/5 (60%) 、 0 error	环境适配域 9 个 commit 修复；简化验证口径，同批补丁可交官方 harness 复评
ARC-Bench 平台 (Train Ticket 143 需求)	—	官方 Linux 容器完成讨论→拆分→模块开发→交付全流程 (3.5h)	分层讨论管线 26% 体量生效；四次运行暴露并修复 12+ 产品缺陷
本地 keep 系列 (32 需求)	—	6/8→8/8 模块交付，验收拒收 点逐轮前移	keep4 管线完整交付 (completed.json) ； keep5 七器官合体 验证中

逐次运行日志、计费单（¥15.85 / ¥20.22 / ¥24.50 / ¥29.62）与缺陷-修复对照见 NIGHT_REPORT.md，全程 git 可回溯。

七、ARC-Bench 契约对齐（官方容器实弹验证）

- 需求摄取：requirements.yaml (FOLDER/ATOMIC) + 参考截图视觉转写注入；
- 过程上报：Pipeline 事件 → 官方 SDK (事件流 + traceability + git 提交) ， 本地无 SDK 自动 no-op；
- 运行契约：PORT 环境变量 / GET /api/health 200 / 首页 200 / 启动即灌种子 (helpers.ts 精确字符串) ；
- 环境对齐：官方 Linux 容器依赖装通、2GB 内存哨兵、143 需求全流程 3.5h 实测；
- 交付弹性：单模块失败冻结继续，部分交付仍进 Playwright 评测。

八、路线图

时间	里程碑
9/15-16	keep 系列迭代至全链 PASS (分层管线+七审计器+全链保护首次合体)
9/17-18	功能冻结 + 提交包冻结 + 模拟环境全流程彩排
9/21	初赛开题：下载赛题 → 实弹首单 → 平台真实基线

9/22-29	数据驱动迭代：平台反馈 → 修复 → 重交（按配额节奏）
9/30	提交截止：最终版本确认 + 状态核验

token-burner · AI 多智能体项目团队系统 · ARC-Bench 参赛作品 · 文档版本 2026-09-15 · 数据口径：NIGHT_REPORT.md（全程 git 可回溯）