

token-burner · 文档消耗器

AI 多智能体项目团队系统

可行性研究报告

(v2.0 竞赛版 · 2026 年 9 月)

一、执行摘要

token-burner（文档消耗器）是一套 AI 多智能体项目团队系统：以「主 LLM 架构师 + 开发副 LLM + 测试副 LLM」三角色编队协作，把一句自然语言软件需求转化为一个可运行、经验证、可审计的完整 Web 项目（代码、测试、接口契约、变更记录与成本看板全程交付）。

与市面单模型编码助手相比，本版本的差异化壁垒已从「成本护栏」单一卖点，升级为三重体系：其一，六层确定性成本护栏（预算总闸、讨论轮数、单轮输出、循环检测、修复上限、spec 收敛）；其二，七类确定性审计器（schema 一致性、包结构、符号级导入、机械垫片、子模块绑定、内存哨兵、轨迹取证）——零 LLM 调用、由实弹失败取证驱动；其三，模型链全

链保护与 模块级优雅冻结——单模型超时自动接力编队内其余模型，单模块失败冻结继续，部分交付仍可评测。

本报告从技术、产品、经济、风险四个维度论证项目可行性。截至本版本，项目已完成 ARC-Bench 官方容器环境六次实弹运行验证（含 143 需求的 Train Ticket 全流程），累计 1231 项自动化回归 测试全绿，单任务真实计费基线 750k~1.2M token（折合 ¥15.85~29.62）已取得。

二、项目背景与市场分析

2.1 行业痛点

- 成本失控：多智能体系统以多轮对话与多模型协作提升质量，同时放大 token 消耗；讨论发散、修复死循环、单次输出倾泻等场景使账单不可预期；
- 集成无人管：生成式系统的故障面集中在模块结合部——import 命名漂移、数据库种子丢失、跨模块契约不一致，文件单看都对、拼在一起即不可运行；
- 质量无闸门：主流工具生成的代码缺乏接口契约、静态审计与真实执行反馈闭环，「看起来对」不等于「跑得对」；
- 只写不验：验证环节缺失或形同虚设（虚过），失败被掩盖到部署期才暴露。

2.2 市场定位

AI 编码是生成式 AI 商业化落地最快、付费意愿最强的赛道之一。本产品不做又一个编码助手，而定位为「AI 软件团队的操作系统 + 财务总监」：过程可视、成本可控、交付可证。ARC-Bench 等新一代「需求 → 可运行应用」基准的兴起，验证了自治开发团队品类的评测口径：以真实浏览器端到端测试的通过率为唯一主分，以效率（通过率/成本）为同分排序——与本产品「诚实验收 + 成本治理」设计逐项对位。

2.3 目标客群

- 基准评测与竞技场景：ARC-Bench 等自治开发基准的参赛团队与组织方；
- 中小软件团队与外包公司：需要降低开发成本、但无法承担 AI 账单失控风险；
- 企业 IT 部门：需要可审计、可预算管理的生成式开发工具以满足合规要求；
- AI 工具集成商与开发者：通过提交包/CLI 将多智能体内核嵌入自有工作流。

三、技术可行性

3.1 系统架构与生产流水线

系统采用分层架构：交互层（桌面客户端 / Web 工作台 / CLI / 平台提交包，共用同一契约）→ 编排层（任务路由、团队组建、方案讨论、分层讨论管线）→ 执行层（LocalExecutor 进程级 / DockerExecutor 容器沙箱双实现）→ 交付层（代码 + 测试 + 变更记录 + 成本看板）。

生产流水线八段：评估路由（三分类+难度分）→ 三模型组队（互异校验）→ 方案讨论（PM+双评审， 五层护栏）→ 模块拆分与接口契约（FOLDER 对齐模块、ATOMIC 对齐验收）→ 逐模块开发循环 → 机械组装 → 两段式验收 → 交付。其中分层讨论管线将讨论阶段输入降载至 FOLDER 级摘要（官方 keep 应用实测 26% 体量），117~143 需求的大型应用不再超出模型推理时长。

3.2 六层成本护栏（核心技术壁垒一）

预算总闸 → 讨论轮数护栏 → 单轮输出截断 → 循环检测双保险（Jaccard 文本相似度 + embedding 语义相似度）→ 修复上限 → spec 收敛。关键设计原则：所有护栏由程序确定性执行（AST 解析、 相似度计算、预算累加），不依赖 LLM 自律——成本上界在任务开始前即为确定值。

3.3 七类确定性审计器（核心技术壁垒二）

生成式系统的主要故障面在模块结合部。本产品以七类纯程序审计器（零 LLM 调用）持续校验生成代码 与契约的一致性，每一类均由真实运行失败取证驱动并在真实交付物上回归：

审计器	职责	实弹取证
schema 审计	建表 DDL 与 SQL 引用列名一致性 diff（INSERT 清单 / WHERE 谓词 / 限定引用 / SELECT 清单 / 表名漂移，5 类检查）	两次平台实弹连续命中
包结构审计	import 名与实际包名映射；空壳包识别	keep 系列
符号级导入审计	from X import sym 静态验证 sym 在 X 内有定义	keep 系列
机械垫片	命名漂移自动生成 re-export 垫片（零 LLM 修复）	平台实弹
子模块自动绑定	同名子模块属性缺失自动补绑定	keep 系列
内存哨兵	应用峰值内存超限判不合格（对齐 2GB 官方环境）	官方环境裁决
轨迹取证	失败自动携带应用侧 traceback（file:line）注入修复指令	三次实弹定位

配套「修复形态约束」：审计结论注入修复指令时，同步约束修复形态（直接修改目标代码，禁止新增 运行时自适应/兼容层），防止修复模型以过度工程「回应」诊断而非「服从」诊

断。该体系与成本护栏 共同构成双技术壁垒。

3.4 模型韧性体系

- 模型链全链保护：单模型调用超时自动接力编队内其余模型，全灭以专用异常类型（ModelChainExhausted）上抛——备胎调用本身受保护，不再裸奔；
- 模块级优雅冻结：单模块模型链全灭 → 冻结该模块、管线继续其余模块——部分交付仍进评测， 优于全盘归零；预算超支等闸门类异常不受影响，继续按原语义中止；
- 验收优雅降级：验收失败 → 报告完整保留、干净退出，绝不崩穿宿主进程（官方容器实证）；
- 空内容防线：LLM 空响应当作该模型失败自动接力备胎（修复计划曾因空内容直接死掉）；
- 配置锚定与编制自动补全：配置随提交包锚定与运行目录解耦；官方中转站上编制不足 三模型时按已知可用编队自动补全。

3.5 视觉理解通道

需求树内嵌的参考截图（reference/*.png）自动经视觉模型转写为结构化中文描述（布局分区/导航文案/ 表单控件/数据元素/配色）注入需求文本。官方环境注入的 VISUAL_MODEL / VISUAL_BASE_URL 视觉端点 优先使用，中转站视觉模型作兜底；带描述缓存（断点不重复计费）、逐级降级与幻觉防线（无效输入 绝不上发）。官方 keep 应用 22 张参考截图实测全识别，描述与真实界面逐项吻合。

3.6 已验证的工程成果

- 1231 项自动化回归测试全绿（全 stub 设计，无需密钥），全程 SDD+TDD；
- ARC-Bench 官方 Linux 容器六次实弹运行：Train Ticket（143 需求）完成讨论→拆分→模块开发→ 交付全流程（3.5 小时）；依赖安装、SDK 事件上报、traceability 落盘全部通过；
- 视觉转写通道：官方 keep 应用 22 张参考截图全识别，官方视觉端点优先接入；
- 真实计费基线：单任务 750k~1.2M token = ¥15.85~29.62（官方计费系统口径）。

结论：技术方案全部落地且经实弹验证，无未解决的技术阻塞项。

四、产品可行性

4.1 产品形态

三种交付形态共用同一内核契约：桌面客户端（pywebview 原生窗口，面向非技术用户）、Web 工作台（实时监控/对话流图/成本看板/连接向导）、headless CLI 与平台提交包（面向

评测与自动化集成）。另有 VS Code 插件（活动栏面板发起任务/实时进度/成本看板）。

4.2 开发方法论带来的交付确定性

项目全程采用 SDD + TDD：任何功能先有规格条款、后有实现与对应测试。「产品是否做完」是可机检 问题而非主观判断。17 轮实弹演练以「每轮失败取证 → 修复 → 回归」循环推进，期间新增确定性 审计器六类、修复韧性机制四项，全部带专项测试合入。

4.3 实弹数据支撑

- 官方容器六次实弹：从单模型无备胎崩穿，到全链保护+七审计器武装的完整交付，防御体系以 可测量的方式逐轮增厚；
- SWE-bench Lite：修复前基线 resolved 1/50（2%）；环境适配域修复后同域新样本 3/5（60%）、0 error——确定性诊断路线的有效性在第二域独立复现。

五、经济可行性

5.1 成本结构（实测口径）

产品边际成本为 LLM API 的 token 费用。实测基线（Train Ticket 143 需求，官方容器）：单任务 750k~1.2M token，折合 ¥15.85~29.62；keep（32 需求）规模约 500k token。六层护栏确保成本上界确定：超支即干净中止、现场落盘、断点续跑，不产生不可控账单。

降本路径已验证三条：分层讨论管线（讨论输入降载 74%）、环境预检闸门（不可评实例零 token 拦截）、描述缓存（视觉转写断点不重复计费）。模型档位路由（难度分三档分发）为下一阶段 降本手段，预期进一步压缩 30% 以上。

5.2 商业化路径

- 订阅制（SaaS）：按任务预算档位订阅，护栏与看板为付费核心；
- 私有化部署：面向数据合规敏感的企业，按席位/年授权；
- API 计量：面向集成商按调用量计费，多智能体内核作为 PnP 组件。

注：以上为方向性框架，具体定价需以初赛阶段真实用量数据校准。

六、风险分析与对策

风险	对策	状态
----	----	----

网关退化窗口（慢流/超时）	墙钟上限 + 指数退避 + 模型链自动接力 + 模块冻结	已上线，实弹验证
单任务评测时限	分层讨论管线（74% 降载）+ 模块并行化（规划中）	部分上线
模型价格波动/下线	多模型中转 + 编制自动补全 + 档位路由可配置	已上线
生成代码安全	Docker 沙箱 / 进程降级双模式 + 危险 API 预扫描 + 不可信输入数据边界	已上线
竞争同质化	确定性审计器与成本治理为实证壁垒；契约对齐持续跟随官方口径	持续迭代
修复不收敛	轨迹取证 + 审计注入 + 修复形态约束；轮次按诊断发现动态增配	部分上线

七、结论与建议

token-burner v2.0 竞赛版已完成 1231 项自动化测试全绿、ARC-Bench 官方容器六次实弹运行验证，成本护栏与确定性审计器双技术壁垒均经真实失败取证驱动并带回归测试锁死；单任务真实计费基线（¥15.85~29.62）已经取得，成本上界确定可控。

建议：项目具备进入初赛冲刺的条件——按既定路线完成功能冻结（9/17-18）、提交包彩排与稳定性演练后，以当前版本参与初赛；初赛真实评分数据回流后，再评估效率档位优化与商业化 Beta 的启动时点。

token-burner • 文档消耗器 • AI 多智能体项目团队系统 • 可行性研究报告（v2.0 竞赛版）• 2026 年 9 月 • 全文数据口径见 NIGHT_REPORT.md, git 全程可回溯