

token-burner · 文档消耗器

AI 多智能体项目团队系统

可行性研究报告

(通用版 · 2026 年 9 月)

一、执行摘要

token-burner (文档消耗器) 是一套 AI 多智能体项目团队系统: 以「主 LLM 架构师 + 开发副 LLM + 测试副 LLM」三角色编队协作, 把一句自然语言软件需求转化为一个可运行、经验证、可审计的完整 Web 项目 (代码、测试、接口契约、变更记录与成本看板全程交付)。

与市面单模型编码助手相比, 本产品的差异化壁垒为三重体系: ①六层确定性成本护栏 (预算总闸、讨论轮数、单轮输出、循环检测、修复上限、spec 收敛); ②七类确定性审计器 (schema 一致性、包结构、符号级导入、机械垫片、子模块绑定、内存哨兵、轨迹取证) —— 零 LLM 调用、由实弹失败取证驱动; ③模型链全链保护与模块级优雅冻结 —— 单模型超时自动接力编队内其余模型, 单模块失败冻结继续, 部分交付仍可评测。

本报告从技术、产品、经济、风险四个维度论证项目可行性。截至本版本，项目已完成 1231 项自动化 回归测试全绿，17 轮实弹迭代验证，单任务实测成本 750k~1.2M token。

二、项目背景与市场分析

2.1 行业痛点

- 成本失控：多智能体系统以多轮对话与多模型协作提升质量，同时放大 token 消耗；
- 集成无人管：生成式系统故障面集中在模块结合部——import 漂移、种子丢失、契约不一致；
- 质量无闸门：缺乏接口契约、静态审计与执行反馈闭环，「看起来对」不等于「跑得对」；
- 只写不验：验证环节缺失或形同虚设，失败被掩盖到部署期才暴露。

2.2 市场定位

AI 编码是生成式 AI 商业化落地最快、付费意愿最强的赛道之一。本产品不做又一个编码助手，而定位为「AI 软件团队的操作系统 + 财务总监」：过程可视、成本可控、交付可证。新一代「需求 → 可运行应用」基准的兴起，验证了自治开发团队品类的评测口径。

2.3 目标客群

- 中小软件团队与外包公司：需要降低开发成本、但无法承担 AI 账单失控风险；
- 企业 IT 部门：需要可审计、可预算管理的生成式开发工具以满足合规要求；
- AI 工具集成商与开发者：通过提交包/CLI 将多智能体内核嵌入自有 workflow。

三、技术可行性

3.1 系统架构与生产流水线

系统采用分层架构：交互层（桌面客户端 / Web 工作台 / CLI / 平台提交包）→ 编排层（任务路由、团队组建、方案讨论、分层讨论管线）→ 执行层（LocalExecutor 进程级 / DockerExecutor 容器沙箱双实现）→ 交付层。生产流水线八段：评估路由 → 三模型组队 → 方案讨论 → 模块拆分与接口契约 → 逐模块开发循环 → 机械组装 → 两段式验收 → 交付。其中分层讨论管线将讨论阶段输入降载至 FOLDER 级摘要（实测 26% 体量），117~143 需求的大型应用不再超出模型推理时长。

3.2 六层成本护栏（核心技术壁垒一）

预算总闸 → 讨论轮数护栏 → 单轮输出截断 → 循环检测双保险 → 修复上限 → spec 收敛。关键设计原则： 所有护栏由程序确定性执行，不依赖 LLM 自律——成本上界在任务开始前即为确定值。

3.3 七类确定性审计器（核心技术壁垒二）

审计器	职责	实弹取证
schema 审计	建表 DDL 与 SQL 引用列名一致性 diff（5 类检查）	多轮实弹命中
包结构审计	import 名与实际包名映射；空壳包识别	keep 系列
符号级导入审计	from X import sym 验证 sym 在 X 内有定义	auth_bp 案例
机械垫片	命名漂移自动生成 re-export 垫片	gen 家族终结
子模块自动绑定	同名子模块属性缺失自动补绑定	seed_data 案例
内存哨兵	应用峰值内存超限判不合格	生产环境对齐
轨迹取证	失败自动携带应用侧 traceback（file:line）注入修复	三次实弹定位

配套「修复形态约束」：直接修改目标代码，禁止新增运行时自适应层。

3.4 模型韧性体系

- 模型链全链保护：单模型超时自动接力编队内其余模型；
- 模块级优雅冻结：单模块失败冻结该模块、管线继续其余模块；
- 验收优雅降级：验收失败报告完整保留、干净退出；
- 空内容防线：LLM 空响应当作失败自动接力备胎；
- 配置锚定与编制自动补全。

3.5 视觉理解通道

支持多模态需求输入：需求树内嵌参考截图自动经视觉模型转写为结构化中文描述注入需求文本。带描述缓存（断点不重复计费）、逐级降级与幻觉防线。22 张截图实测全识别。

3.6 已验证的工程成果

- 1231 项自动化回归测试全绿（全 stub 设计，无需密钥），全程 SDD+TDD；
- 17 轮实弹迭代：从单模型无备胎崩穿，到全链保护+七审计器武装的完整交付；
- 大规模需求验证：143 需求项目全流程实测，分层讨论管线降载 74% 生效；
- 真实成本基线：单任务 750k~1.2M token。

结论：技术方案全部落地且经实弹验证，无未解决的技术阻塞项。

四、产品可行性

4.1 产品形态

三种交付形态共用同一内核契约：桌面客户端、Web 工作台、headless CLI 与平台提交包。

4.2 开发方法论带来的交付确定性

项目全程采用 SDD + TDD：任何功能先有规格条款、后有实现与对应测试。「产品是否做完」是可机检问题而非主观判断。17 轮实弹演练以「每轮失败取证 → 修复 → 回归」循环推进。

4.3 实弹数据支撑

- 多轮实弹迭代：从单模型无备胎崩穿，到全链保护+七审计器武装的完整交付；
- SWE-bench Lite：修复前基线 resolved 1/50 (2%)；环境适配域修复后同域新样本 3/5 (60%)、0 error——确定性诊断路线的有效性在第二域独立复现。

五、经济可行性

5.1 成本结构（实测口径）

产品边际成本为 LLM API 的 token 费用。实测基线：单任务 750k~1.2M token（约 ¥15~30）——具体成本取决于需求规模与修复轮次。六层护栏确保成本上界确定。

降本路径已验证三条：分层讨论管线（讨论输入降载 74%）、环境预检闸门（不可评实例零 token 拦截）、描述缓存（视觉转写断点不重复计费）。模型档位路由为下一阶段降本手段。

5.2 商业化路径

- 订阅制（SaaS）：按任务预算档位订阅，护栏与看板为付费核心；
- 私有化部署：面向数据合规敏感的企业，按席位/年授权；
- API 计量：面向集成商按调用量计费，多智能体内核作为 PnP 组件。

六、风险分析与对策

风险	对策	状态
网关退化窗口	墙钟上限 + 指数退避 + 模型链自动接力 + 模块冻结	已上线
单任务评测时限	分层讨论管线 + 模块并行化	部分上线
模型价格波动/下线	多模型中转 + 编制自动补全 + 档位路由	已上线
生成代码安全	Docker 沙箱 + 危险 API 预扫描 + 数据边界	已上线
竞争同质化	确定性审计器与成本治理为实证壁垒	持续迭代
修复不收敛	轨迹取证 + 审计注入 + 修复形态约束	部分上线

七、结论与建议

token-burner v2.0 已完成 1231 项自动化测试全绿、17 轮实弹迭代验证，成本护栏与确定性审计器双技术壁垒均经真实失败取证驱动并带回归测试锁死；单任务真实成本基线（¥15~30）已经取得，成本上界确定可控。

建议：项目具备交付能力——以当前版本进行客户验证；真实数据回流后，再评估效率优化与商业化启动时点。

token-burner • 文档消耗器 • AI 多智能体项目团队系统 • 可行性研究报告（通用版）• 2026 年 9 月
• 全文数据口径见 NIGHT_REPORT.md, git 全程可回溯